

# Unfallatlas Deutschland

## Schweregrad-Klassifikation von Verkehrsunfällen in Deutschland

Projekt-Handout nach dem QUA<sup>3</sup>CK-Prozessmodell

Question → Understanding the Data → Algorithm/Adapt/Adjust → Conclude & Compare → Knowledge Transfer

Jonas Weirauch | IU Internationale Hochschule, B.Sc. Data Analytics / Big Data

[github.com/jonasyr/unfallatlas-qua3ck](https://github.com/jonasyr/unfallatlas-qua3ck) | [Live-Report \(GitHub Pages\)](#) | [Streamlit-App](#)

**Kurzfassung:** Aus 2,09 Mio. Unfallatlas-Datensätzen (2016-2024) plus offen lizenzierten Wetter- (DWD) und Straßennetz-Daten (OSM) wird die Unfallschwere vorhergesagt. Das ursprüngliche 3-Klassen-Ziel erweist sich als mit den verfügbaren Merkmalen nicht erreichbar (Ceiling Macro-F1 = 0,424) und wird auf eine binäre KSI-Variable (getötet/schwerverletzt vs. leichtverletzt) reframt. Der finale Random-Forest-Champion erreicht auf dem unberührten Testjahr 2024 Macro-F1 = 0,604 und Recall(KSI) = 0,515, beide Zielkriterien erfüllt. Das Ergebnis ist als interaktive Streamlit-App und als statische Notebook-Präsentation live nutzbar.

### 1 Q: Frage

**Forschungsfrage:** Welche raumzeitlichen, infrastrukturellen und meteorologischen Faktoren bestimmen die Schwere eines Verkehrsunfalls in Deutschland, und lässt sich diese Schwere zuverlässig aus öffentlich verfügbaren Daten mittels interpretierbarer Machine-Learning-Modelle vorhersagen?

**Hypothesen:** (H1) Unfallzeitpunkt (Wochentag, Stunde, Monat) korreliert mit der Schwere, z. B. höhere Schwere bei Nachtfahrten oder außerorts. (H2) Beteiligungsart (Fußgänger, Rad, Motorrad) ist ein stärkerer Schwere-Prädiktor als reine Ortsmerkmale, da ungeschützte Verkehrsteilnehmer überproportional betroffen sind. (H3) Wetter- und Straßeninfrastrukturmerkmale liefern einen messbaren, aber untergeordneten Zusatzbeitrag gegenüber Unfallart/-typ.

**Datenquelle:** Unfallatlas Deutschland (GovData/Mobilithek, Statistisches Bundesamt), Datenlizenz Deutschland, Namensnennung 2.0, 2016-2024, rund 2,09 Mio. polizeilich erfasste Unfälle mit Personenschaden. Zielvariable UKATGEORIE: 1 = Getötet (1 %), 2 = Schwerverletzt (18 %), 3 = Leichtverletzt (81 %): eine stark unbalancierte 3-Klassen-Variable.

**Teststrategie:** Chronologischer Split statt Zufallssplit, da die Daten Zeitreihencharakter haben (Unfallzahlen, Fahrzeugbestand und Infrastruktur verändern sich über die Jahre): Train 2016-2022, Validierung 2023, Test 2024. Damit wird das Modell stets an *zukünftigen*, nie an zufällig gemischten Daten geprüft, ein realistischeres Szenario für ein produktiv genutztes Frühwarn- oder Priorisierungswerkzeug als ein zufälliger Train/Test-Split.

**Relevanz & Einordnung:** Interpretierbare Schwere-Vorhersage ist für Verkehrssicherheitsplanung (Ressourcenpriorisierung bei Unfallhäufungsstellen), Versicherungswesen und Rettungsdienst-Planung relevant. Die bewusste Wahl klassischer, gut erklärbarer Modelle (Random Forest, Boosting, lineare Modelle) statt Deep-Learning-Ansätzen folgt der Anforderung, dass Entscheidungsträger:innen die Vorhersagegründe nachvollziehen können müssen (siehe C-Phase, Permutation Importance).

| Zielmetrik                          | Schwelle |
|-------------------------------------|----------|
| Macro-F1 (Test 2024)                | ≥ 0,55   |
| Recall Klasse 1 (Getötet)           | ≥ 0,50   |
| Baseline Macro-F1 (Mehrheitsklasse) | ≈ 0,30   |

## 2 U: Untersuchung der Daten

Explorative Datenanalyse (EDA) und Feature-Engineering ergänzen die 21 Rohspalten des Unfallatlas um externe, offen lizenzierte Quellen, alles offline reproduzierbar über `duckdb` auf dem konsolidierten Parquet (`data/accidents.parquet`, 65 MB, verwaltet via Git LFS), ohne die 2,09 Mio. Zeilen vollständig nach pandas laden zu müssen.

- **Wetter (DWD, CDC Open Data):** Windgeschwindigkeit, Niederschlag; je Unfall wird die räumlich/zeitlich nächste DWD-Station verknüpft (`dwd_station_id`, `dwd_station_dist_km`).
- **Straßennetz (OpenStreetMap, ODbL):** Straßendichte und zulässige Höchstgeschwindigkeit im Umkreis, aggregiert über H3-Hexagon-Zellen statt teurer Punkt-für-Punkt-Lookups gegen das OSM-Straßennetz: notwendig, um den Join auf 2,09 Mio. Punkten in vertretbarer Zeit auf einem normalen Laptop durchzuführen.
- **Zeitliche Merkmale:** Wochentag (`UWOCHENTAG`), Stunde (`USTUNDE`), Monat (`UMONAT`): die EDA zeigt klare Spitzen im Berufsverkehr sowie saisonale Schwankungen.
- **Räumliche Merkmale:** Regierungsbezirk-/Kreis-Code (`UREGBEZ/UKREIS`), Breiten-/Längengrad. Ohne Bundesland-Schlüssel (`ULAND`) im Inference-Contract sind (`UREGBEZ,UKREIS`)-Paare *nicht* global eindeutig auf einen amtlichen Kreisnamen abbildbar; die App zeigt sie deshalb bewusst als dataset-interne Codes statt erfundener Kreisnamen.
- **Beteiligungsmerkmale:** Binärflags je Verkehrsmittel (`IstPKW`, `IstRad`, `IstKrad`, `IstFuss`, `IstGkfz`, `IstSonstig`).
- **Unfalltyp & Zustand:** Unfallart/-typ (`UART`, `UTYP1`), Lichtverhältnisse (`ULICHTVERH`) und Straßenzustand (`STRZUSTAND`).

**Zentraler EDA-Befund:** Die Zielverteilung ist extrem unbalanciert (1 % Getötet, 81 % Leichtverletzt), und einzelne Merkmale korrelieren nur schwach mit der Schwere (Cramér's  $V \leq 0,13$  für die stärksten Merkmale). Diese schwache Merkmals-Ziel-Assoziation ist der entscheidende Vorbote für den Ceiling-Befund der A<sup>3</sup>-Phase.

**Datenqualität:** Vor der Modellierung wurden Plausibilitätsprüfungen durchgeführt (Wertebereiche der Koordinaten gegen die Landesgrenzen Deutschlands, Konsistenz der Kategorie-Codes gegen die amtliche Datensatzbeschreibung `DSB_Unfallatlas.md`, Duplikatsprüfung über die Unfall-ID). Fehlende DWD-/OSM-Zuordnungen (z. B. bei sehr abgelegenen Unfallorten) werden nicht imputiert, sondern als fehlender Wert weitergereicht, damit Modelle sie explizit als Information nutzen können, statt eine künstliche Zuordnung vorzutauschen.

## 3 A<sup>3</sup>: Algorithmus, Anwendung, Anpassung

### Der 3-Klassen-Ceiling und die Reframing-Entscheidung

Über 19 getestete Konfigurationen, darunter Baselines, lineare Modelle, Baum-/Boosting-Modelle, Imbalance-Strategien (Klassengewichtung, Over-/Undersampling) sowie Optuna-basiertes Hyperparameter-Tuning, erreicht das 3-Klassen-Ziel nur einen empirischen **Ceiling von Macro-F1** = 0,424, deutlich unter dem Akzeptanzkriterium von 0,55. Für eine brauchbare Precision der Getötet-Klasse wäre eine  $\sim 90$ -fache Odds-Lift nötig, ein Effekt, den die verfügbaren Merkmale (Cramér's  $V \leq 0,13$ ) schlicht nicht hergeben.

**Konsequenz:** Reframing auf eine **binäre KSI-Variable** (Killed or Seriously Injured vs. Leichtverletzt), die in der internationalen Unfallforschungsliteratur etablierte Standardformulierung (Santos 2022; Pakgohar 2021; Schloessler 2024), die das seltene, sicherheitskritische Ereignis von der Alltagsverletzung trennt, statt drei ungleich seltene Klassen simultan zu modellieren.

### Kandidatenvergleich (Stufe 0/1, Validierung 2023)

Zehn klassengewichtete/balancierte Kandidaten wurden auf identischer Merkmalsbasis verglichen; die Auswahl erfolgt gate-bewusst (`select_best_candidate`): höchster Macro-F1 unter allen Kandidaten mit

Recall(KSI)  $\geq 0,50$ , sonst höchster Kombi-Score.

| Modell                          | Macro-F1     | Rec. KSI     | Rec. Leicht  |
|---------------------------------|--------------|--------------|--------------|
| Zufallsrat.                     | 0,439        | 0,499        | 0,499        |
| Mehrheitsklasse                 | 0,453        | 0,000        | 1,000        |
| Logistic Regression             | 0,558        | 0,638        | 0,634        |
| <b>Random Forest (Champion)</b> | <b>0,601</b> | <b>0,540</b> | <b>0,747</b> |
| XGBoost                         | 0,570        | 0,682        | 0,633        |
| LightGBM                        | 0,566        | 0,690        | 0,624        |
| CatBoost                        | 0,565        | 0,686        | 0,624        |
| SVM (linear)                    | 0,559        | 0,636        | 0,636        |
| SVM (RBF)                       | 0,560        | 0,606        | 0,651        |
| SVM (SGD)                       | 0,553        | 0,654        | 0,618        |

**Champion:** Random Forest (balanciert), Hyperparameter `n_estimators=180`, `max_depth=23`, `min_samples_leaf=8`; Entscheidungsschwelle 0,4986 (auf Val 2023 optimiert). Val-Macro-F1 0,608, Recall(KSI) 0,505: beide Zielgates auf Val 2023 erfüllt. Trainingsumfang:  $\sim 1,55$  Mio. Zeilen (2016-2022); SVM-Varianten wurden aus Laufzeitgründen auf Subsamples (8 000-500 000 Zeilen) trainiert.

## 4 C: Auswertung & Vergleich

### Testergebnis (Held-out 2024)

Macro-F1 = 0,604, Recall(KSI) = 0,515, Recall(Leicht) = 0,769: beide Akzeptanzgates werden auf den unberührten 2024-Daten erneut erfüllt, ein wichtiges Indiz gegen Overfitting auf den Validierungssatz.

### Warum der Champion nicht der Top-Kandidat ist

Auf der *kombinierten* Kriterienmenge (Recall, Inferenzlatenz, Robustheit über Resampling-Wiederholungen) liegen die drei Boosting-Finalisten (XGBoost/LightGBM/CatBoost) beim Recall(KSI) klar vorne (0,68-0,69 vs. 0,54) und sind gleichzeitig 3-4 $\times$  schneller in der Inferenz (12-15 ms/1000 vs. 43,6 ms/1000 Zeilen). Nach diesen Zahlen ist Random Forest also *nicht* der bevorzugte Finalist. Er bleibt dennoch **Deployment-Champion**, weil die Modellauswahl bereits mittels Validierungsdaten festgelegt wurde, *bevor* der Testsatz angefasst wurde: der Held-out-2024-Satz kann nicht nachträglich zur Neuauswahl zwischen Kandidaten verwendet werden, ohne die statistische Unabhängigkeit der bereits für Random Forest berichteten Testmetriken zu verletzen. Dieser methodische Punkt (Validierung entscheidet, der Test bestätigt nur) ist zentral für die Glaubwürdigkeit des berichteten Ergebnisses und wird in der App (Modellvergleich-Seite) explizit erläutert.

### Permutation Importance (Champion-Modell)

SHAP wurde zugunsten von Permutation Importance verworfen (bessere Skalierbarkeit auf  $\sim 270\,000$  Testzeilen ohne Kernel-Approximation). Top-Merkmale:

| Merkmal                      | Importance |
|------------------------------|------------|
| UART (Unfallart)             | 0,0304     |
| UTYP1 (Unfalltyp)            | 0,0175     |
| IstKrad (Motorrad beteiligt) | 0,0129     |
| IstRad (Fahrrad beteiligt)   | 0,0106     |
| STRZUSTAND (Straßenzustand)  | 0,0082     |
| USTUNDE (Unfallstunde)       | 0,0066     |

Unfallart/-typ und die Beteiligung ungeschützter Verkehrsteilnehmer (Motorrad, Fahrrad) dominieren die Vorhersage, plausibel und konsistent mit Hypothese H2, aber *korrelativ, nicht kausal*.

## Limitationen

Polizeiliche Meldequote variiert nach Schweregrad (schwerere Unfälle werden zuverlässiger erfasst als leichte, sogenannter Meldebias); Regierungsbezirk/Kreis-Codes sind ohne Bundesland-Schlüssel nicht eindeutig lokalisierbar; Rasterzellen der Kartenansicht sind keine Verwaltungsgrenzen; relative Risikowerte in der Overview-Karte sind statistische Assoziation, kein Kausalnachweis; Shrinkage-Glättung ( $k = 20$ ) verzerrt kleine Stichproben absichtlich Richtung Landesdurchschnitt, um Overfitting auf dünn besetzte Zellen zu vermeiden, ein bewusster Fairness-/Robustheits-Trade-off, kein Fehler.

## 5 K: Wissenstransfer (Kommunikation)

Die Ergebnisse werden über zwei sich gegenseitig verlinkende Oberflächen kommuniziert: eine interaktive Streamlit-App und eine statische Notebook-Präsentation.

### Streamlit-App (`app/streamlit_app.py`)

Läuft vollständig aus committeten `data/processed/`-Artefakten (Modelle, Contract, Kartendaten); kein Notebook-Rerun nötig.

- **Overview:** Kennzahlen-Konsole (Macro-F1, Recall(KSI), Entscheidungsschwelle), Gegenüberstellung 3-Klassen-Ceiling vs. Binär-Ergebnis, interaktive OSM-Karte mit KSI-Risiko relativ zum Landesdurchschnitt (diskrete Risikobänder, einzeln umschaltbar, Konfidenz-Transparenz für dünn besetzte Zellen).
- **Risikoprädiktor:** Klickbare Karte (Folium/OSM) statt manueller Lon/Lat-Eingabe: ein Klick setzt Position und Formular in einem Schritt; Formular für Kontextmerkmale (Zeit, Beteiligung, Straßenzustand); Live-Vorhersage inkl. Konfidenz relativ zur Entscheidungsschwelle.
- **Warum diese Vorhersage:** Permutation-Importance-Chart und Eingabetabelle mit menschenlesbaren Feature-Labels (z. B. `dwd_wind_speed_ms` → „Windgeschwindigkeit (m/s)“) statt Rohspaltennamen.
- **Modellvergleich:** Alle 10 Kandidaten, Pareto-Front (Macro-F1 vs. Recall(KSI)), Konfusionsmatrix des Champions (Test 2024), Erklärung der Champion-vs-Finalist-Entscheidung (siehe C-Phase oben).

### Notebook-Präsentation & Deployment

Die vier ausgeführten Q/U/A<sup>3</sup>/C-Notebooks werden zusätzlich als statisches, offline-fähiges HTML (Code, Text, sowie interaktive Plotly-Grafiken) über GitHub Pages veröffentlicht, ohne lokale Installation einsehbar. App und Notebook-Präsentation sind gegenseitig verlinkt, sodass Leser:innen zwischen Analyse-Nachvollziehbarkeit (Notebooks) und interaktiver Exploration (App) wechseln können. Deployment der App erfolgt über Streamlit Community Cloud, Branch `main`, ohne dass Notebooks zur Laufzeit neu ausgeführt werden müssen.

### Fazit & Ausblick

Das Projekt zeigt exemplarisch, wie ein zunächst nicht erreichbares Klassifikationsziel durch begründetes, literaturgestütztes Reframing (3-Klassen → binäre KSI-Variable) doch noch belastbare, handlungsrelevante Ergebnisse liefert, und wie wichtig die saubere Trennung von Validierungs- und Testdaten für die Glaubwürdigkeit einer Modellauswahl ist. Mögliche Erweiterungen: Einbindung des amtlichen Gemeindeschlüssels (ULAND) für belastbare Kreis-Namen, Kalibrierung der Vorhersagewahrscheinlichkeiten, sowie eine zeitbasierte „Risk-Scan“-Simulation auf der Overview-Karte (aktuell bewusst zurückgestellt, um Umfang und Qualität der bestehenden Fixes nicht zu gefährden).

## Tech-Stack

| Bereich            | Bibliotheken                                              |
|--------------------|-----------------------------------------------------------|
| Daten              | pandas, polars, duckdb, pyarrow                           |
| ML                 | scikit-learn, xgboost, lightgbm, catboost                 |
| Imbalance & Tuning | imbalanced-learn, optuna                                  |
| Erklärbarkeit      | Permutation Importance (statt SHAP)                       |
| Geodaten           | folium, streamlit-folium (optional: geopandas, h3, osmnx) |
| App                | streamlit                                                 |
| Tooling            | uv, ruff, pytest, jupyter, pre-commit                     |

## Projektstruktur & Reproduzierbarkeit

Der gesamte Ablauf ist ohne manuelle Zwischenschritte reproduzierbar: `git lfs pull` (Datensatz) → `uv sync --all-extras` (Abhängigkeiten) → `uv run streamlit run app/streamlit_app.py` (App) bzw. `uv run jupyter lab` (Notebooks). Kein Schritt erfordert einen Notebook-Rerun, da alle für App und Präsentation nötigen Artefakte bereits unter `data/processed/` committet sind.

| Verzeichnis      | Inhalt                                                                                                |
|------------------|-------------------------------------------------------------------------------------------------------|
| notebooks/       | QUA <sup>3</sup> CK-Phasennotebooks (Source of Truth): Q, U, A <sup>3</sup> , C                       |
| src/unfallatlas/ | Wiederverwendbare Bibliothek (data/, features/, models/, viz/, presentation/)                         |
| app/             | Streamlit-Demo (K-Phase): Overview, Risikoprädiktor, Warum diese Vorhersage, Modellvergleich          |
| data/            | accidents.parquet (Git LFS) sowie interim/- und processed/-Artefakte (Modelle, Contract, Kartendaten) |
| tests/           | pytest-Suite inkl. Coverage-Report und optionalen Playwright-Browstertests                            |
| docs/            | Disclosure, Glossar, Datensatzbeschreibung, Prompt-Transkripte je Phase                               |
| reports/         | Generierte Abbildungen und Notebook-Präsentationen (GitHub Pages)                                     |

Qualitätssicherung läuft identisch lokal und in CI (GitHub Actions): `uv run pytest` (Tests inkl. Coverage), `uv run ruff check .` (Linting), `uv run ruff format .` (Formatierung) sowie Pre-Commit-Hooks (Ruff, nbstripout, Commitizen, Notebook-Mirror-Check).

**Weiterführende Ressourcen:** [GitHub-Repository](#) | [Live-Report \(Notebooks als HTML\)](#) | [Streamlit-App](#) | Dokumentation: docs/GLOSSARY.md, docs/AI TOOL DISCLOSURE.md, docs/dataset/

Code: MIT-Lizenz. Unfalldaten: Datenlizenz Deutschland, Namensnennung 2.0 (Mobilithek/Statistisches Bundesamt, Unfallatlas Deutschland). Wetterdaten: Deutscher Wetterdienst (DWD), CDC Open Data. Straßennetz: © OpenStreetMap-Mitwirkende, ODbL.