

Ablauf, Zeit und Sprungpunkte

ZEITBUDGET, 37 FOLIEN IN 30 BIS 40 MINUTEN

- Einstieg (1-4): 4 Min
- Q-Phase (5-8): 5 Min
- U-Phase (9-16): 9 Min
- A³-Phase (17-24): 9 Min
- C-Phase (25-31): 8 Min
- K-Phase (32-34): 4 Min
- Fazit, Quellen, Dank (35-37): 2 Min

KÜRZEN ERLAUBT, NIEMALS KÜRZEN

- Kürzbar bei Zeitnot: Folie 11 (Datenqualität), 24 (Threshold), 31 (Contract).
- Niemals kürzen: Folie 16 (Machbarkeitswarnung), 20 (arithmetische Decke), 21 (Reframing), 27 (Champion bleibt).

JETZT ZEIGEN

- Nach **14**: Live-Report, U-Phase, Abschnitt 6 „Bivariate analysis“, Cramér's-V-Heatmap. 30 Sek.
- Nach **22**: App, *Model Comparison*, „Pareto front: macro-F1 vs. Recall(KSI)“. 45 Sek.
- Nach **27**: App, *Model Comparison*, Aufklapper „Warum bleibt Random Forest der Champion?“. 30 Sek.
- Nach **32**: App, *Risk Predictor*, „Try an example“ anklicken, Vorhersage zeigen. 60 Sek.
- Nach **33**: App, *Overview*, „Where accidents are disproportionately severe“, Risikobänder umschalten. 45 Sek.

VOR DEM START PRÜFEN

- Drei Tabs offen: Repo (github.com/jonasyr/unfallatlas-qua3ck), Live-Report (jonasyr.github.io/unfallatlas-qua3ck), App (Streamlit Cloud).
- App einmal vorher aufrufen. Kaltstart dauert bis zu 30 Sekunden.

FOLIE 1 | Einstieg

Titel

Ich habe die Schwere von Verkehrsunfällen in Deutschland aus öffentlichen Daten vorhergesagt und methodische Sauberkeit wichtiger genommen als eine hohe Zahl.

SAGEN

- Name, Titel, Datengrundlage in einem Satz. Nicht die Folie vorlesen.
- Drei Live-Artefakte ankündigen: Repository, Live-Report, Streamlit-App.
- Ansagen, dass ich an passenden Stellen kurz hineinspringe.

BEGRIFFE

- **QUA³CK**: Prozessmodell für ML-Projekte. Question, Understanding, Algorithm/Adapt/Adjust, Conclude & Compare, Knowledge Transfer.
- **Unfallatlas**: Offener Datensatz der Statistischen Ämter des Bundes und der Länder. Jeder polizeilich erfasste Unfall mit Personenschaden seit 2016, eine Zeile pro Unfall.

Agenda

Die Präsentation folgt exakt dem QUA³CK-Prozess, weil das Projekt so entstanden ist.

SAGEN

- Die fünf Phasen kurz durchgehen, nicht erklären.
- Spannungsbogen setzen: „Die A³-Phase ist die interessanteste, weil dort das ursprüngliche Ziel gescheitert ist und ich es begründet ändern musste.“

Das QUA³CK-Prozessmodell

QUA³CK zwingt dazu, die Erfolgskriterien festzulegen, bevor man die Daten kennt, und macht ein Scheitern damit überhaupt erst erkennbar.

SAGEN

- Jeden Buchstaben einmal aussprechen.
- Kernpunkt: Das Modell ist **iterativ**. Spätere Phasen dürfen frühere Entscheidungen widerlegen.
- Betonen: Genau das ist hier passiert. Das ist kein Fehler im Prozess, das ist der Prozess.

BEGRIFFE

- **A³**: Drei Tätigkeiten in einer Phase. *Algorithm*: Welche Modellfamilie? *Adapt*: Wie passe ich die Daten an, vor allem an das Klassenungleichgewicht? *Adjust*: Wie stelle ich die Hyperparameter ein?
- **Iterativ**: Kein einmaliger linearer Durchlauf, sondern Rücksprung, wenn eine spätere Phase eine frühere Annahme widerlegt.

WENN GEFRAGT

- **Warum QUA³CK und nicht CRISP-DM?** Kursvorgabe, inhaltlich sehr ähnlich. QUA³CK trennt die drei A-Tätigkeiten explizit, CRISP-DM fasst sie unter „Modeling“. Gemeinsamer Kern: Die Fachfrage steht vor der Modellierung.

Motivation

Kommunen entscheiden über Verkehrssicherheit meist auf Basis von Unfallzahlen, nicht auf Basis von Bedingungsprofilen. Genau diese Lücke adressiert das Projekt.

SAGEN

- Einstieg mit der Zahl: rund 270.000 Unfälle mit Personenschaden pro Jahr.
- Verteilung nennen, sie prägt die ganze Präsentation: **1 / 18 / 81 Prozent**.
- Nutzen: Ein Modell, das aus Bedingungen auf Schwere schließt, kann priorisieren statt nur zählen.
- Bewusste Ausschlüsse deutlich sagen: keine individuellen Fahrer-Risikoscores, keine Versicherungstarifizierung. Vorab festgelegt.

BEGRIFFE

- **Vision Zero:** Ursprünglich schwedisches, heute EU-weites Ziel: bis 2050 keine Verkehrstoten und Schwerverletzten. Der politische Rahmen solcher Analysen.
- **BASt:** Bundesanstalt für Straßenwesen. Gibt jährlich „Unfallentwicklung auf deutschen Straßen“ heraus.
- **DVR:** Deutscher Verkehrssicherheitsrat.

Die Forschungsfrage

Die Frage war von Anfang an gestuft formuliert, mit vorab definiertem Ausweichpfad. Die spätere Zieleänderung ist damit Teil des Designs, keine nachträgliche Rechtfertigung.

SAGEN

- Die Frage einmal langsam vorlesen, sie ist lang.
- Entscheidender Punkt: Sie startet mit dem Drei-Klassen-Ziel und bleibt explizit offen für eine „evidenzgetriebene operative Umformulierung“.
- Vorhergesagt wird aus Bedingungen, die zum Zeitpunkt der Protokollerstellung vorliegen.
- In der A³-Phase auf diese Folie zurückverweisen.

► „Das ist kein nachträglicher Rettungsanker. Das stand in Phase Q im Notebook, bevor das erste Modell trainiert wurde.“

WENN GEFRAGT

- **Sagt das Modell vorher, ob ein Unfall passiert?** Nein. Es setzt voraus, dass ein Unfall passiert ist, und schätzt, wie schwer er ausgeht. Unfallvorhersage bräuchte Expositionsdaten, also Verkehrsmengen. Die hat dieser Datensatz nicht.

Hypothesen

Drei überprüfbare Hypothesen: zu Zeit und Wetter, zu Ortskontext und zur gestuften Machbarkeit.

SAGEN

- H1 und H2 sind inhaltlich, H3 ist methodisch.
- Bei H2 die Einschränkung mitsprechen: Geschwindigkeit, Infrastrukturqualität und Rettungszeit sind plausible Mechanismen, werden aber nicht gemessen. Kein Kausalanspruch.
- Ergebnis in einem Halbsatz vorwegnehmen:
 - H1 nur schwach bestätigt, die Wetter-Assoziationen sind sehr klein.
 - H2 in der schwachen Form bestätigt, Ortsmerkmale tragen messbar bei.
 - H3 ist der eigentliche Befund der Arbeit.

BEGRIFFE

- **Hypothese:** Vorab formulierte, überprüfbare Aussage. Entscheidend ist die Falsifizierbarkeit: Sie muss durch die Daten widerlegbar sein.
- **Baseline:** Bewusst einfaches Vergleichsmodell. Schlägt das komplexe Modell die Baseline nicht, hat der Aufwand keinen Nutzen.

Zielmetriken und Akzeptanzkriterien

Macro-F1 als Primärmetrik plus ein zweites Gate auf dem Recall der seltensten Klasse, damit kein Modell dadurch gut aussieht, dass es die kritischste Klasse ignoriert.

MACRO-F1 VON UNTEN AUFBAÜEN

- **Precision** einer Klasse: Von allen als diese Klasse vorhergesagten Fällen, wie viele waren es wirklich?
- **Recall** einer Klasse: Von allen Fällen, die wirklich diese Klasse sind, wie viele hat das Modell gefunden?
- **F1:** Harmonisches Mittel aus beiden. Harmonisch, weil es bestraft, wenn einer der beiden Werte sehr klein ist.
- **Macro-F1:** Einfacher Durchschnitt der F1-Werte über alle Klassen. Jede Klasse zählt gleich viel, egal wie selten sie ist.

SAGEN

- Schlüsselbeispiel: Ein Modell, das immer „Leichtverletzt“ sagt, hat 81 Prozent Accuracy. Klingt gut, ist wertlos. Macro-F1 etwa 0,30, Recall auf die tödliche Klasse null.
- Selbst Macro-F1 könnte man theoretisch über die beiden häufigen Klassen erreichen.
- Das Recall-Gate auf Klasse 1 verhindert genau das.
- Auswahldisziplin ansagen: Modellwahl und Schwellenwert nur auf Validierung 2023. Test 2024 wird genau einmal geöffnet. **Wird auf Folie 27 gebraucht.**

WENN GEFRAGT

- **Warum harmonisches Mittel bei F1?** Das arithmetische Mittel von Precision 1,0 und Recall 0,0 wäre 0,5, obwohl das Modell nutzlos ist. Das harmonische Mittel ergibt hier 0. Es bestraft Ungleichgewicht zwischen beiden Größen.

Rahmenbedingungen und Ethik

Interpretierbarkeit war eine harte Vorgabe, keine Kür. Die Ergebnisse informieren Infrastrukturentscheidungen, nicht Urteile über Personen.

SAGEN

- Zügig durchgehen, das ist eine Absicherungsfolie. Nur zwei Punkte betonen.
- **Interpretierbarkeitsvorgabe:** Sie erklärt, warum kein neuronales Netz im Kandidatenfeld ist. Ein Verkehrsplaner muss nachvollziehen können, warum ein Ort als Risiko markiert wurde.
- **Ethische Rahmung:** Merkmalswichtigkeiten sind Assoziationen, keine Ursachen. Dieser Hinweis steht auch in der App selbst.

BEGRIFFE

- **Batch-Inferenz:** Vorhersagen werden gebündelt für viele Fälle berechnet, nicht in Echtzeit einzeln. Senkt die Anforderungen deutlich.
- **DSGVO-Konformität quellseitig:** Der Datensatz enthält von vornherein keine personenbezogenen Daten. Keine Namen, kein Alter, kein Geschlecht. Die Frage der Anonymisierung stellt sich damit gar nicht.

Der Datensatz im Steckbrief

2,09 Millionen Unfälle über neun Jahre, 21 Spalten, öffentlich lizenziert, vollständig ohne Personenbezug.

SAGEN

- Tabelle nicht vorlesen. Drei Zahlen nennen: **2.092.401 Zeilen, 21 Spalten, 2016 bis 2024.**
- Merkmalsgruppen in einem Durchgang: Zeit, Unfallcharakter, Umgebung, Beteiligung, Raum.
- COVID-Beleg, zeigt dass ich die Daten wirklich angeschaut habe: 2020 bricht ein, 2024 ist mit 268.519 wieder auf dem Niveau von 2019 mit 268.370.

BEGRIFFE

- **UKATGEORIE:** Die Zielvariable. Im Quelldatensatz steht tatsächlich „UKATGEORIE“ mit Tippfehler statt „UKATEGORIE“. Die Schreibweise der Quelle wurde bewusst unverändert übernommen.
- **UART vs. UTYP1:** UART ist die *Unfallart*, also die Kollisionsform (Auffahrunfall, Zusammenstoß mit Fußgänger). UTYP1 ist der *Unfalltyp*, also die auslösende Konfliktsituation (Abbiegeunfall, Fahrrunfall). Beide werden nach dem Unfall vergeben.
- **Parquet:** Spaltenorientiertes Dateiformat. Speichert Spalte für Spalte statt Zeile für Zeile, dadurch sehr schnelle Abfragen auf wenige Spalten und starke Kompression.
- **Git LFS:** Large File Storage. Git-Erweiterung, die große Binärdateien außerhalb der Versionsgeschichte speichert und im Repository nur einen Zeiger ablegt.
- **DuckDB:** Eingebettete analytische Datenbank, konzeptionell wie SQLite, aber spaltenorientiert. Führt SQL direkt auf Parquet aus, ohne Import.

Zielvariable und Imbalance

Ein Klassenverhältnis von 1 zu 18 zu 81 macht Accuracy wertlos und führt ohne Gegenmaßnahme zum Mehrheitsklassen-Kollaps.

SAGEN

- Verteilung nennen, sofort die Konsequenz: Ein Modell, das nichts lernt, bekommt 81 Prozent Accuracy geschenkt.
- **Stabilität über die Jahre:** Die Klassenanteile schwanken über neun Jahrgänge um weniger als einen Prozentpunkt. Das rechtfertigt den chronologischen Split. Gäbe es starke Drift, wäre Training auf alten Jahren wertlos.
- **Dunkelziffer** aktiv ansprechen, ehrlichster Punkt der Datenphase: Was wir sehen, ist auch eine Verteilung des Meldeverhaltens, nicht nur der Realität. Leichte Unfälle werden seltener gemeldet. Aus dem Datensatz heraus nicht korrigierbar.

BEGRIFFE

- **Klassenungleichgewicht:** Die Klassen sind sehr unterschiedlich häufig. Das Problem ist nicht die Ungleichheit selbst, sondern dass Standardverfahren die Gesamtfehlerrate minimieren und deshalb die seltene Klasse ignorieren.
- **Mehrheitsklassen-Kollaps:** Das Modell hat gelernt, immer die häufigste Klasse vorherzusagen, weil das die Fehlerrate minimiert.
- **Dunkelziffer:** Die unbekannte Zahl nie gemeldeter Unfälle.

Datenqualität und Plausibilisierung (kürzbar)

Fünf Klassen von Prüfungen wurden systematisch durchgeführt, und imputiert wurde bewusst erst später in der Pipeline, nicht hier.

SAGEN

- Bei Zeitnot: nur den letzten Punkt machen.
- **Warum in Phase U nicht imputiert wird:** Eine Imputation über den gesamten Datensatz zieht Information aus Validierung und Test ins Training. Der Median einer Spalte über alle Daten enthält Information aus dem Testjahr 2024. Das ist Leakage.
- Konsequenz: Jede Imputation wandert in die sklearn-Pipeline und wird dort pro Fold nur auf Trainingsdaten gefittet.
- Ehrlichkeitspunkt: 8 Prozent Geokodierungsausfall. Der Datensatz ist bereits vorgefiltert, bevor wir ihn bekommen, und diese Filterung ist nicht zufällig.

BEGRIFFE

- **Sentinel-Wert:** Ein spezieller Zahlenwert, der „kein Messwert“ bedeutet, etwa minus 999. Wird er nicht erkannt, rechnet das Modell mit einer echten Temperatur von minus 999 Grad.
- **Imputation:** Auffüllen fehlender Werte, zum Beispiel mit dem Median.
- **Selektionsverzerrung:** Die Stichprobe ist nicht zufällig aus der Grundgesamtheit gezogen. Hier: Nur geokodierbare Unfälle sind enthalten, und Geokodierbarkeit hängt vermutlich mit dem Ortstyp zusammen.

Anreicherung 1: DWD-Wetterdaten

Jeder Unfall wurde über einen k-d-Baum mit der nächsten Wetterstation verknüpft, mit 99 Prozent räumlicher Abdeckung, aber erheblichen Lücken bei Wind und Sicht.

SAGEN

- k-d-Baum erklären: Naiv bräuchte man für 2,09 Mio. Unfälle die Distanz zu rund 400 Stationen, also fast eine Milliarde Berechnungen. Ein k-d-Baum teilt den Raum rekursiv auf, sodass ganze Teilbäume beim Suchen ausgeschlossen werden. Laufzeit unter 30 Sekunden.
- **Join-Detail, das oft übersehen wird:** Der Unfallatlas hat kein Tagesdatum, nur Jahr, Monat, Stunde. Also wird über alle Tage eines Monat-Stunde-Buckets gemittelt. Unfall am 3. Juli um 14 Uhr bekommt das Mittel aller 14-Uhr-Messungen im Juli.
- Das ist Rauschen, aber kein Leakage: Die Zukunft fließt nicht ein.
- **Ehrlichkeitspunkt aktiv nennen:** Windgeschwindigkeit fehlt zu 50,8 Prozent, Sichtweite zu 54,4 Prozent. Dokumentiert und an A³ als Risiko übergeben.

BEGRIFFE

- **k-d-Baum:** Datenstruktur zur schnellen Nächste-Nachbarn-Suche in mehrdimensionalen Räumen.
- **CDC:** Climate Data Center, das Open-Data-Portal des DWD. **GeoNutzV:** die Verordnung, unter der DWD-Daten frei nutzbar sind.
- **Proxy-Variable:** Ein Merkmal, das für etwas anderes steht, das man nicht direkt messen kann. `dwd_station_dist_km` ist ein Proxy für ländliche Lage. Geprüft: Die Todesrate fernab von Stationen liegt über 20 Prozent höher. Deshalb bewusst behalten, obwohl es eigentlich ein Datenqualitäts-Artefakt ist.

Anreicherung 2: OSM-Straßenkontext über H3

Statt für 2,09 Millionen Punkte einzeln die nächste Straße zu suchen, wurde das Straßennetz einmal auf ein Hexagon-Gitter aggregiert.

SAGEN

- Erst das Problem: Ein Nächste-Straße-Lookup für 2,09 Mio. Punkte gegen das gesamte deutsche Straßennetz ist auf einem Laptop nicht praktikabel.
- H3 erklären: Uber-System, zerlegt die Erdoberfläche hierarchisch in Sechsecke. Auf Stufe 8 ist eine Zelle etwa 0,7 Quadratkilometer groß.
- **Warum Sechsecke und nicht Quadrate?** Bei Sechsecken haben alle sechs Nachbarn denselben Mittelpunktsabstand. Bei Quadraten sind die diagonalen Nachbarn weiter weg als die orthogonalen. Für Nachbarschaftsanalysen sauberer.
- Der Trick: Straßennetz einmal pro Bundesland laden und auf Zellen aggregieren. Danach ist der Join pro Unfall nur noch ein Nachschlagen der Zellen-ID, praktisch kostenlos.
- **Dokumentierte Näherung offen ansprechen:** OSM bildet das heutige Netz ab, die Unfälle reichen bis 2016 zurück. Ein Tempolimit kann sich geändert haben. Akzeptierte Approximation, kein Leakage, weil OSM-Daten nicht vom Unfallausgang abhängen.

BEGRIFFE

- **H3:** Hexagonales hierarchisches Geo-Indexsystem von Uber.
- **OSM:** OpenStreetMap, offenes von Freiwilligen gepflegtes Kartenprojekt. Lizenz ODbL.
- **Expositionsproxy:** `osm_road_density` steht indirekt für Verkehrsaufkommen. Wo mehr Straße ist, fährt in der Regel mehr Verkehr.

Zentrale EDA-Befunde

Kein einziges Merkmal erreicht auch nur Cramér's V von 0,15 zur Zielvariable. Das schwache Signal ist der zentrale Befund der Datenphase.

SAGEN

- Diese Folie ist die Vorbereitung auf das spätere Scheitern. Sorgfältig machen.
- Cramér's V erklären: Maß für den Zusammenhang zweier kategorialer Variablen, abgeleitet aus dem Chi-Quadrat-Test, normiert auf 0 bis 1.
- Einordnung liefern: unter 0,1 vernachlässigbar, 0,1 bis 0,3 schwach, 0,3 bis 0,5 mittel, darüber stark. **0,13 ist also am unteren Rand von schwach, und das ist der beste Wert im ganzen Datensatz.**
- Anschaulichster Teil, die zeitlichen Muster: Die meisten Unfälle passieren im Nachmittagsverkehr, die schwersten nachts. Wer zählt, sieht den Nachmittag. Wer Schwere betrachtet, sieht die Nacht.
- Negativbefund bewusst nennen: Monatlicher Niederschlag und monatliche Todesrate bewegen sich nicht gemeinsam. Ein berichtetes Nullergebnis ist ein Qualitätsmerkmal.

JETZT ZEIGEN

Live-Report → U Phase → Abschnitt **6 Bivariate analysis: feature × target**. Nur die **Cramér's-V-Heatmap** zeigen, auf die dunkelste Zelle (UART) deuten und die 0,13 vorlesen. Nicht scrollen. 30 Sekunden.

BEGRIFFE UND WENN GEFRAGT

- **EDA:** Exploratory Data Analysis. Das systematische Anschauen der Daten vor der Modellierung.
- **Warum nicht Korrelation?** Pearson setzt metrische Variablen und einen linearen Zusammenhang voraus. Unfallart ist nominal, ohne Ordnung. Da ist Korrelation nicht definiert. Cramér's V ist das passende Gegenstück für kategoriale Variablen.

Leakage-Prüfung und chronologischer Split

Leakage wurde aktiv gemessen, nicht angenommen. Der Split ist chronologisch, weil ein Zufallssplit bei Zeitreihendaten die Realität verfälschen würde.

SAGEN

- Leakage zuerst definieren, danach wird am ehesten gefragt: Informationen, die zum Vorhersagezeitpunkt nicht verfügbar wären, gelangen ins Training. Folge sind Leistungswerte, die im echten Einsatz nicht halten.
- Konkrete Sorge hier: UART und UTYP1 werden nach dem Unfall vergeben. Steckt in diesen Kategorien die Schwere schon implizit? Dann wäre es ein Zirkelschluss.
- Die Sonde, bedingte Entropiereduktion: Entropie misst Unsicherheit. $H(Y)$ ist die Unsicherheit über die Schwere ohne Wissen, $H(Y|X)$ die verbleibende Unsicherheit, wenn Merkmal X bekannt ist. Die Reduktion sagt, wie viel Prozent der Unsicherheit das Merkmal wegnimmt.
- Ergebnis: UART nimmt 3,4 Prozent weg, UTYP1 2,2 Prozent. Weit unter der 50-Prozent-Auslöseschwelle. Kein Merkmal musste raus.
- Split begründen: Bei einem Zufallssplit könnte das Modell auf 2024er-Daten trainieren und auf 2019er-Daten getestet werden. Das entspricht nicht dem Einsatz, wo man immer in die Zukunft vorhersagt.
- Verifikation erwähnen: Keine OBJECTID kommt in mehr als einem Split vor. Geprüft, nicht angenommen.

Die Machbarkeitswarnung (nicht kürzen)

Die Datenphase endete mit einer dokumentierten Warnung, dass das ursprüngliche Ziel möglicherweise nicht erreichbar ist. Und zwar bevor das erste Modell trainiert wurde.

SAGEN, WENDEPUNKT DER PRÄSENTATION, ZEIT NEHMEN

- Erstens: Die tödliche Klasse ist etwa 1 Prozent der Daten.
 - Zweitens: Die stärkste Assoziation ist Cramérs V von 0,13, also schwach.
 - Drittens, der eigentliche Grund, hier langsam werden: Die physikalisch entscheidenden Determinanten fehlen komplett. Aufzählen: Aufprallgeschwindigkeit, Alter der Insassen, Gurnutzung, Fahrzeugmasse, Anstoßgeometrie.
- „Ob ein Unfall tödlich endet, entscheidet sich vor allem an der kinetischen Energie und daran, wie verletzlich der Mensch im Fahrzeug ist. Genau diese Größen enthält der öffentliche Datensatz nicht. Was er enthält, ist der Kontext drumherum.“
- „Diese Warnung wurde dokumentiert, bevor das erste Modell trainiert wurde. Das ist der Unterschied zwischen einer belegten Vorhersage und einer nachträglichen Ausrede.“

Aufbau der Modellierung

Alles läuft in einer sklearn-Pipeline, damit Vorverarbeitung niemals über die Split-Grenzen leckt.

SAGEN

- **Pipeline**, der methodisch wichtigste Punkt: Verkettet Vorverarbeitung und Modell zu einem Objekt mit gemeinsamem `fit` und `predict`. Fittet die Kreuzvalidierung das Objekt pro Fold neu, werden auch Skalierung, Encoding und Imputation nur auf dem Trainingsteil dieses Folds gefittet.
- **Zyklische Kodierung**, lohnt 20 Sekunden: Stunde 23 und Stunde 0 liegen eine Stunde auseinander, als Zahlen aber 23. Kodiert man die Stunde als Sinus-Kosinus-Paar auf einem Kreis, ist der Abstand wieder korrekt.
- **Target-Encoding**: Statt 87 Kreis-Spalten per One-Hot wird jeder Kreis durch den mittleren Zielwert seiner Trainingszeilen ersetzt, mit Glättung gegen Überanpassung bei seltenen Kreisen.
- **GroupKFold**: Gruppiert nach Unfalljahr, damit kein Modell im selben Jahr trainiert und validiert.
- **Audit-Modus**, starker Punkt: Das Notebook bricht ab, wenn eine persistierte Metrik nicht auf 1e-9 genau reproduziert wird. Die Zahlen in dieser Präsentation sind nicht abgetippt, sie werden bei jedem Lauf gegengeprüft.

BEGRIFFE

- **One-Hot-Encoding**: Eine Kategorie mit k Ausprägungen wird zu k Null-Eins-Spalten.
- **Kardinalität**: Anzahl verschiedener Ausprägungen einer Kategorie.
- **Seed**: Startwert des Zufallszahlengenerators. Fixiert man ihn, sind Zufallsentscheidungen reproduzierbar.

19 Konfigurationen gegen das Drei-Klassen-Ziel

Keine der 19 getesteten Konfigurationen erreicht den zulässigen Bereich. Die beste Macro-F1 liegt bei 0,424 gegenüber der geforderten 0,55.

SAGEN

- Tabelle nicht vorlesen, stattdessen das Muster zeigen. Es gibt zwei Gruppen:
 - Brauchbare Macro-F1, miserabler Recall auf die tödliche Klasse. Oben Random Forest balanced mit 0,424 und 0,212.
 - Brauchbarer Recall, schlechte Macro-F1. XGBoost und LightGBM balanced mit rund 0,60 Recall, aber nur 0,37 Macro-F1.
 - Einwand vorwegnehmen: Auch eine nachträgliche Verschiebung der Entscheidungsgrenze über einen zweidimensionalen Offset-Sweep erreicht das Gate nicht. Es wurde also nicht nur „nicht genug getunt“.
- „Das Gate verlangt beides gleichzeitig. Und genau die Kombination existiert nicht. Es gibt keinen Punkt im zulässigen Quadranten.“

BEGRIFFE

- **balanced (Klassengewichtung):** Fehler auf seltenen Klassen werden im Trainingsverlust stärker gewichtet, typischerweise umgekehrt proportional zur Klassenhäufigkeit.
- **Threshold Moving:** Nachträgliches Verschieben der Entscheidungsschwelle, ohne das Modell neu zu trainieren.
- **Offset-Sweep:** Systematisches Durchprobieren additiver Verschiebungen auf den Logits der Minderheitsklassen, um zu prüfen, ob irgendein Arbeitspunkt das Gate erreicht.

Warum Oversampling das Problem verschlimmert

SMOTE und ADASYN lassen den Recall auf die tödliche Klasse auf ein bis drei Prozent kollabieren. Nur Klassengewichtung wirkt überhaupt.

SAGEN

- **SMOTE** erklären: Synthetic Minority Over-sampling Technique. Statt seltene Beispiele zu duplizieren, sucht SMOTE zu einem Minderheitsbeispiel seine nächsten Nachbarn derselben Klasse und erzeugt neue Punkte auf den Verbindungslinien dazwischen.
 - **ADASYN:** adaptive Variante, erzeugt mehr Beispiele dort, wo die Klassifikation schwer ist.
 - **Frank-Hall-Zerlegung:** Nutzt aus, dass die Klassen geordnet sind. Statt drei Klassen direkt zu lernen, lernt man zwei binäre Fragen: „schwerer als 1?“ und „schwerer als 2?“. Elegant, aber hier mit Recall 0,003 die schlechteste Strategie.
 - Schluss: Nur Klassengewichtung hebt den Recall über 0,50. Ein Befund, der der Intuition widerspricht, denn SMOTE gilt als Standardwerkzeug.
 - Wichtig: SMOTE darf nur auf Trainingsdaten angewendet werden, niemals auf Validierung oder Test. Sonst Leakage.
- „SMOTE interpoliert zwischen echten Beispielen. Das funktioniert, wenn die Klassen im Merkmalsraum getrennt liegen. Hier überlappen sie fast vollständig, weil das Signal so schwach ist. Ein interpolierter Punkt zwischen zwei tödlichen Unfällen landet mitten in einer Wolke aus Leichtverletzten. Man erzeugt kein Signal, man erzeugt Rauschen.“

Die arithmetische Decke (Schlüssselfolie)

Unabhängig vom Modell lässt sich ausrechnen, dass das Gate eine etwa 90-fache Odds-Anhebung erfordert, die ein Signal von Cramérs V 0,13 nicht liefern kann.

DIE VIER SCHRITTE LANGSAM DURCHGEHEN

- **Schritt 1:** F1 auf der Mehrheitsklasse liegt bei etwa 0,72. Macro-F1 ist der Durchschnitt über drei Klassen. Damit er 0,55 erreicht, müssen die anderen beiden zusammen im Mittel etwa 0,46 beitragen.
- **Schritt 2:** Klasse 1 macht 0,94 Prozent aus. Für F1 von 0,46 bei Recall mindestens 0,50 braucht man Precision von etwa 0,42. Also: Von allen als tödlich vorhergesagten Unfällen müssten 42 Prozent wirklich tödlich sein.
- **Schritt 3,** Odds-Rechnung: Odds sind Wahrscheinlichkeit geteilt durch Gegenwahrscheinlichkeit. Basisrate 0,94 Prozent ergibt Odds von etwa 0,0095. Precision 0,42 ergibt Odds von etwa 0,72. Faktor dazwischen: rund 90.
- **Schritt 4:** Die stärkste Assoziation im Datensatz liegt bei Cramérs V von 0,13. Ein so schwaches Signal kann diese Konzentration nicht erzeugen.
- Abschluss: Empirische Front und arithmetische Anforderung zeigen unabhängig voneinander auf dasselbe Ergebnis.

► „Das Modell müsste eine Teilgruppe finden, in der ein Unfall rund 90-mal wahrscheinlicher tödlich endet als im Durchschnitt. Nicht 90 Prozent mehr. 90-mal.“

WENN GEFRAGT

- **Ist die 90 exakt?** Nein, eine Größenordnungsrechnung. Je nach Rundung landet man zwischen 76 und 90. Der Punkt ist nicht die zweite Nachkommastelle, sondern die Größenordnung: Es braucht eine Konzentration um fast zwei Zehnerpotenzen.

Das Reframing auf binäres KSI (Schlüssselfolie)

Die Zielvariable wurde auf KSI gegen Leichtverletzt umgestellt. Vorab definiert, sicherheitsrelevant und mit unverändertem Split.

SAGEN

- Entscheidung: Das Drei-Klassen-Ziel bleibt als dokumentierter Hintergrund, ist aber nicht länger primär. Begründung in einem Satz: Weiteres Tuning würde dieselbe Suche in schwachem Signal wiederholen, ohne die verfügbare Information zu verändern.
- **KSI:** Killed or Seriously Injured, getötet oder schwerverletzt. Etablierter Begriff in der Verkehrssicherheitsarbeit, weil er die planerisch relevante Grenze zieht.
- Die drei Rechtfertigungen sicher können:
 - **Vorab definiert.** Verweis zurück auf Folie 5 und H3. Der Fallback stand im Q-Phase-Notebook, bevor modelliert wurde.
 - **Sicherheitsrelevant.** Der Unterschied zwischen schwer und leicht verletzt ist der Unterschied, an dem sich Maßnahmen entscheiden.
 - **Statistisch tragfähig.** Aus 1 Prozent positiver Klasse werden etwa 19 Prozent.
- Methodische Sauberkeit zeigen: Der zeitliche Split und die Leakage-Grenze bleiben unverändert. Es wird nichts nachträglich angepasst außer der Zielvariable selbst.

WENN GEFRAGT

- **Ist das nicht einfach das Problem leichter machen?** Ja, die Aufgabe wird leichter, und das sage ich offen. Der Unterschied zu unsauberem Vorgehen ist dreifach: Der Pfad war vorab definiert. Die ursprüngliche Zielverfehlung wird vollständig berichtet, nicht gelöscht. Die neue Aufgabe bleibt inhaltlich relevant.
- **Warum nicht Getötet gegen Rest?** Das hätte genau das 1-Prozent-Seltenheitsproblem behalten. KSI ist die in der Verkehrssicherheitsliteratur übliche Zusammenfassung und löst das Häufigkeitsproblem, ohne die planerische Relevanz zu verlieren.

Zehn Kandidaten im binären Setting

Zehn Modellfamilien von der Zufallsbaseline bis zu drei Boosting-Verfahren, alle auf identischer Merkmalsbasis und nur auf Validierung verglichen.

SAGEN

- Baselines zürst, sie zeigen dass das Modell wirklich etwas lernt: Zufallsraten 0,439, Mehrheitsklasse 0,453. Das ist die Latte, alles darüber ist echter Lerngewinn.
- **Random Forest**: Viele Entscheidungsbäume, jeder auf einer Zufallsstichprobe der Daten und einer Zufallsauswahl der Merkmale, am Ende wird gemittelt. Idee: Einzelne Bäume überanpassen, aber ihre Fehler sind unkorreliert und mitteln sich weg.
- **Gradient Boosting**: Bäume werden nacheinander gebaut, jeder neue korrigiert die Fehler der bisherigen Summe. XGBoost, LightGBM, CatBoost sind optimierte Implementierungen.
- **SVM**: Support Vector Machine, sucht die trennende Hyperebene mit maximalem Abstand zu den nächsten Punkten.
- Ehrlicher Rechenhinweis aktiv nennen: Der RBF-Kernel-SVM skaliert kubisch mit der Zeilenzahl. Bei 1,55 Mio. Trainingszeilen nicht machbar, deshalb auf 8.000 Zeilen gesampelt.

JETZT ZEIGEN

App → *Model Comparison* → Abschnitt „**Pareto front: macro-F1 vs. Recall(KSI)**“. Auf den Gate-Bereich deuten und zeigen, welche Kandidaten ihn erfüllen. Tabelle „All 10 candidates“ nur kurz streifen. 45 Sekunden.

BEGRIFFE

- **Bagging vs. Boosting**: Bagging (Random Forest) trainiert viele Modelle parallel auf Zufallsstichproben und mittelt. Boosting trainiert sequenziell, jedes Modell korrigiert die Fehler der Vorgänger.
- **Blattweises Wachstum (LightGBM)**: Der Baum wächst dort weiter, wo der Gewinn am größten ist, statt Ebene für Ebene. Schneller, aber überanpassungsanfälliger.
- **Kernel-Trick, RBF**: Erlaubt nichtlineare Trennung, indem implizit in einen höherdimensionalen Raum abgebildet wird, ohne diesen explizit zu berechnen. RBF (Radial Basis Function) ist der gebräuchlichste nichtlineare Kernel.

Champion-Auswahl mit Gate-Logik

Random Forest gewinnt als Kandidat mit der höchsten Macro-F1 unter denen, die das Recall-Gate erfüllen. Das Gate ist Vorbedingung, nicht Zielfunktion.

SAGEN

- Die Regel präzise: Nimm alle Kandidaten mit Recall(KSI) von mindestens 0,50. Unter diesen nimm den mit der höchsten Macro-F1.
- **Den scheinbaren Widerspruch selbst ansprechen**: Random Forest hat mit 0,540 den *niedrigsten* KSI-Recall aller Baum- und SVM-Kandidaten. Trotzdem gewinnt er, weil er das Gate erfüllt und unter allen, die es erfüllen, die höchste Macro-F1 hat.
- **Optuna**: Framework für Hyperparameter-Optimierung, das nicht stumpf ein Gitter durchprobiert, sondern modellbasiert sucht. Der Tree-structured Parzen Estimator baut aus den bisherigen Versuchen ein Wahrscheinlichkeitsmodell darüber, welche Parameterbereiche gute Ergebnisse liefern, und probiert dort weiter.
- 20 Trials ergaben 180 Bäume, Tiefe 23, mindestens 8 Beobachtungen pro Blatt. Das hob die Macro-F1 von 0,6011 auf 0,6083.

► „Das Gate ist eine Vorbedingung, keine Zielfunktion. Es sortiert aus, es optimiert nicht.“

BEGRIFFE

- **Hyperparameter**: Einstellungen, die vor dem Training festgelegt werden, im Gegensatz zu Parametern, die das Modell aus den Daten lernt.
- **max_depth**: Maximale Tiefe eines Baums. Begrenzt Komplexität, wirkt gegen Überanpassung.
- **min_samples_leaf**: Mindestanzahl Beobachtungen in einem Blatt. Verhindert, dass Blätter auf einzelne Ausreißer gefittet werden.

Schwellenwert und Negativbefund (kürzbar)

Der Schwellenwert wurde systematisch über 81 Kandidaten optimiert, und ein zweiter Tuning-Versuch wurde nach einer klaren Regel verworfen statt schöngerechnet.

SAGEN

- Punkt, den viele nicht auf dem Schirm haben: Ein Klassifikator gibt eine Wahrscheinlichkeit aus. Erst der Schwellenwert macht daraus eine Entscheidung. Der Default 0,5 ist eine Konvention, keine Optimierung.
- 81 Werte geprüft, der beste unter der Nebenbedingung $\text{Recall} \geq 0,50$: **0,49860**.
- Interessantes Detail: Der optimale Wert liegt sehr nah an 0,5. Kein Zufall, sondern Folge der Klassengewichtung, die die Wahrscheinlichkeiten schon vorher grob ausbalanciert hat.
- **Promotionsregel**: Der neue Versuch wird nur übernommen, wenn er auf *beiden* Achsen nicht schlechter ist. Der Multi-Objective-Versuch hatte besseren Recall (0,5187 gegen 0,5053), aber schlechtere Macro-F1 (0,6057 gegen 0,6083). Also verworfen.

► „Ich hätte auch die Regel nachträglich ändern und den besseren Recall berichten können. Die Regel stand aber vorher fest, und der Versuch ist als gescheiterte Evidenz dokumentiert statt gelöscht.“

BEGRIFFE

- **Multi-Objective-Optimierung**: Optimierung mehrerer Zielgrößen gleichzeitig. Ergebnis ist keine einzelne beste Lösung, sondern eine Pareto-Menge.
- **Pareto-Front**: Die Menge der Lösungen, bei denen man eine Zielgröße nur verbessern kann, indem man eine andere verschlechtert.

Das Testergebnis 2024

Macro-F1 0,604 und Recall(KSI) 0,515 auf einem nie zuvor benutzten Jahr, beide Gates erfüllt, minimaler Abstand zur Validierung.

SAGEN

- Zerst betonen, wie der Test verwendet wurde: genau einmal geöffnet, für genau ein Modell, mit dem vorher festgelegten Schwellenwert.
- Wichtigster Vergleich, Validierung gegen Test: Macro-F1 0,6083 gegen 0,6039. Beim Recall sogar leicht besser, 0,5053 gegen 0,5151.
- Ausdrücklich sagen, warum das gut ist: Wäre das Modell auf der Validierung deutlich besser als auf dem Test, hätte man den Validierungssatz überangepasst. Hier ist der Abstand minimal.
- Konfusionsmatrix in Worte fassen: Von rund 44.200 echten KSI-Unfällen wurden 22.767 erkannt und 21.431 übersehen. Von rund 224.300 Leichtunfällen wurden 172.434 korrekt erkannt und 51.887 fälschlich als KSI markiert.

► „Rund 21.400 KSI-Unfälle werden übersehen. Das Modell ist ein Priorisierungswerkzeug, kein Sicherheitssystem. Im echten Einsatz müsste die Kostenfunktion des Anwenders den Schwellenwert bestimmen, nicht Macro-F1. Wenn ein übersehener schwerer Unfall zehnmal teurer ist als ein Fehlalarm, gehört der Schwellenwert deutlich nach unten.“

BEGRIFFE

- **False Negative**: Ein KSI-Unfall, der als leicht eingestuft wurde. Hier der teure Fehler.
- **False Positive**: Ein Leichtunfall, der als KSI eingestuft wurde. Hier der billigere Fehler, kostet nur Aufmerksamkeit.

Die Entscheidungsmatrix

Über vier gewichtete Kriterien führt XGBoost, nicht das ausgelieferte Modell. Dieses unbequeme Ergebnis wird berichtet statt versteckt.

SAGEN

- Methodik zürst: Sechs Kriterien waren nominal vorgesehen, jedes mit einem Gewicht. Jedes wird min-max-normalisiert, also auf 0 bis 1 skaliert. Kostenkriterien wie Latenz werden invertiert, weil dort niedriger besser ist.
- **Methodische Sorgfalt zeigen:** Zwei Kriterien, Interpretierbarkeit und Trainingskosten, wurden nie gemessen. Statt sie subjektiv zu schätzen und damit das Ergebnis zu färben, wurden sie automatisch ausgeschlossen und die restlichen Gewichte renormalisiert.
- Ergebnis offensiv nennen: XGBoost führt mit 0,561, Random Forest ist Letzter mit 0,500. XGBoost hat mehr Recall und ist dreieinhalbmal schneller.
- Ankündigen, dass die nächste Folie erklärt, warum trotzdem nicht gewechselt wird. Das erzeugt Spannung und verhindert eine vorschnelle Frage.

BEGRIFFE

- **Min-Max-Normalisierung:** Skalierung auf 0 bis 1 über (Wert minus Minimum) geteilt durch (Maximum minus Minimum).
- **Kostenkriterium:** Ein Kriterium, bei dem kleiner besser ist, hier die Latenz. Wird invertiert, damit größer immer besser bedeutet.
- **Latenz ms/1k:** Millisekunden für 1.000 Vorhersagen.

Warum der Champion Champion bleibt (Schlüsselfolie)

Den Champion jetzt zu wechseln würde den Testsatz in den Auswahlprozess ziehen und damit genau die Unabhängigkeit zerstören, die ihn wertvoll macht.

VIER SCHRITTE, 90 SEKUNDEN, WICHTIGSTE FOLIE DER PRÄSENTATION

- **1. Ausgangslage:** Die Modellauswahl fiel in Phase A³ auf Basis der Validierungsdaten 2023. Zu diesem Zeitpunkt war Test 2024 unberührt, reserviert für genau einen Zweck: eine bereits eingefrorene Entscheidung zu bestätigen.
- **2. Was ein Wechsel bedeuten würde:** Wollte ich XGBoost ausliefern, müsste ich für ihn eine Testzahl berichten. Also müsste ich Test 2024 auch für XGBoost auswerten.
- **3. Warum das den Test entwertet:** Dann ist der Testsatz Teil der Auswahl geworden. Ich habe zwei Modelle auf dem Test gemessen und das bessere genommen. Die berichtete Zahl ist das Maximum aus zwei Versuchen, keine unverzerrte Schätzung der Generalisierungsleistung mehr. Rückwirkend wäre auch die Random-Forest-Zahl nicht mehr unabhängig.
- **4. Der Name des Problems:** Data Leakage auf der Ebene der Modellauswahl. Subtiler als Leakage auf Merkmalsebene, weil kein einziger Datenpunkt ins Training wandert. Trotzdem sickert Information aus dem Test in die Entscheidung. In der Praxis die häufigere Form.
- Konsequenz: Random Forest bleibt für diesen Zyklus. XGBoost ist dokumentiert als Kandidat für einen zukünftigen, vorab registrierten Vergleich.

► „Die Validierung entscheidet. Der Test bestätigt nur.“

JETZT ZEIGEN

App → Model Comparison → ganz unten den Aufklapper „**Warum bleibt Random Forest der Champion? (German explanation)**“ öffnen. Nur zeigen, dass die Überlegung im Produkt steht, nicht vorlesen. 30 Sekunden.

WENN GEFRAGT

- **Warum nicht einfach einen neuen Testsatz nehmen?** Es gibt keinen, 2024 ist das letzte verfügbare Jahr. Sobald 2025 veröffentlicht ist, wäre genau das der saubere Weg: vorab festlegen, dass XGBoost gegen Random Forest auf 2025 verglichen wird, und dann einmal messen.
- **Ist das nicht übertrieben streng?** Es ist der Standard, der reproduzierbare Forschung von Zahlenpolitur trennt. Der ganze Wert eines Holdout-Sets liegt darin, dass es genau einmal benutzt wird.

Permutation Importance

Unfallart und Unfalltyp dominieren, gefolgt von der Beteiligung ungeschützter Verkehrsteilnehmer. Modellagnostisch gemessen, damit alle vier Finalisten vergleichbar sind.

SAGEN

- Verfahren zürst, es ist intuitiv: Nimm eine Merkmalsspalte und mische ihre Werte über alle Zeilen zufällig durch. Der Zusammenhang zum Ziel ist zerstört, die Verteilung der Spalte bleibt unverändert. Dann miss, wie stark die Modellleistung einbricht. Großer Einbruch bedeutet: Das Modell war auf dieses Merkmal angewiesen.
- Vorteil gegenüber der eingebauten Feature Importance von Bäumen: modellagnostisch. Man kann Random Forest, XGBoost, LightGBM und CatBoost auf derselben Stichprobe und mit derselben Metrik vergleichen.
- Rangliste plausibilisieren: Unfallart und Unfalltyp vorn. Ein Frontalzusammenstoß ist strukturell gefährlicher als ein Auffahrunfall im Stau. Dann Motorrad- und Fahrradbeteiligung, also ungeschützte Verkehrsteilnehmer. Das bestätigt H2 in der schwachen Form.
- **Warum nicht SHAP?** SHAP erklärt, wie ein *einzelnes* Modell seine transformierten Merkmale nutzt. Für einen Vergleich *zwischen* Modellen das falsche Werkzeug, weil jedes Modell einen anderen transformierten Merkmalsraum hat. Permutation Importance arbeitet auf den Rohspalten und ist deshalb vergleichbar.
- Ehrlicher Zusatz, falls Zeit ist: Die Rangordnungen der vier Modelle stimmen nur mässig überein. Mittlere Spearman-Korrelation zum Champion 0,37, Top-10-Überschneidung etwa 40 Prozent. Die Modelle sind sich einig, dass Unfallart wichtig ist, aber uneinig über die zweite Reihe. Die Rangliste also nicht überinterpretieren.

BEGRIFFE

- **SHAP:** SHapley Additive exPlanations. Verteilt die Abweichung einer Vorhersage vom Mittelwert additiv auf die Merkmale, basierend auf dem Shapley-Wert aus der kooperativen Spieltheorie.
- **Spearman-Korrelation:** Korrelation der Ränge statt der Werte. Passend beim Vergleich von Rangordnungen.
- **Jaccard-Index:** Größe der Schnittmenge geteilt durch Größe der Vereinigungsmenge. Hier: Wie stark überlappen zwei Top-10-Listen?

Robustheit und Modell-Uneinigkeit

Random Forest ist mit 3,77 Prozent gekippten Vorhersagen das stabilste Modell bei fehlenden Merkmalen, und die Boosting-Modelle sind sich untereinander deutlich einiger als mit ihm.

SAGEN

- Robustheitssonde erklären: Fünf Merkmale, die im echten Betrieb realistisch ausfallen können, werden einzeln komplett auf NaN gesetzt. Also: Was passiert, wenn die OSM-Anreicherung ausfällt oder die Wetterstation keine Daten liefert? Gemessen wird, wie viele Vorhersagen dadurch ihre Klasse wechseln.
- Ergebnis: Random Forest 3,77 Prozent, die Boosting-Modelle zwischen 7 und 9 Prozent.
- Eindrücklicher Vergleichswert: SVM über 52 Prozent gekippte Vorhersagen bei einem einzigen fehlenden Merkmal. Starkes praktisches Argument für Baumensembles im Betrieb.
- Paarweise Uneinigkeit: Random Forest gegen die Boosting-Modelle rund 13 Prozent, die Boosting-Modelle untereinander nur 5 Prozent.
- Interpretation: Die drei Boosting-Modelle sind faktisch Varianten derselben Idee. Random Forest ist der methodische Ausreißer, er optimiert auf ausgewogene Klassenleistung und drängt nicht so stark auf KSI-Recall.
- Schlussfolgerung anbieten: Für ein Ensemble wäre Random Forest plus ein Boosting-Modell interessanter als zwei Boosting-Modelle, weil unkorrelierte Fehler sich besser ausgleichen.

BEGRIFFE

- **NaN:** Not a Number, die Standardkodierung für fehlende Werte.
- **Paarweise Uneinigkeit:** Anteil der Fälle mit unterschiedlicher harter Klassenzuweisung zwischen zwei Modellen.

Limitationen

Die Leistungsgrenze liegt in den Daten, nicht im Modell, und alle wesentlichen Einschränkungen sind dokumentiert.

SAGEN

- Zügig, aber vollständig. Das ist eine Stärke, keine Schwäche. Offen benannte Limitationen werden positiv bewertet.
- Wichtigster Punkt sind die fehlenden Merkmale. Zurückverweisen auf Folie 16 und 20: Das ist die Ursache der Leistungsdecke, und sie ist nicht durch bessere Modellierung behebbar.
- Konzeptionell interessanter Schluss: Der Schwellenwert ist eine Wertentscheidung, keine technische. Er kodiert implizit, wie teuer ein übersehener schwerer Unfall im Vergleich zu einem Fehlalarm ist. Diese Abwägung gehört dem Anwender, nicht dem Entwickler.

WENN GEFRAGT

- **Was würde die Leistung am meisten verbessern?** Eindeutig zusätzliche Merkmale, keine besseren Algorithmen. Am wertvollsten wären Aufprallgeschwindigkeit und Insassenalter. Beide sind in Unfallforschungsdatenbanken vorhanden, aber nicht im offenen Datensatz, weil sie personenbezogen oder erhebungsaufwendig sind.

Der Inference Contract (kürzbar)

Eine maschinenlesbare Vertragsdatei fixiert Schema, Wertebereiche, Schwellenwert und Artefakt-Prüfsumme, damit die App ohne Notebook-Ausführung korrekt arbeitet.

SAGEN

- Problem: Wer eine Anwendung auf ein Modell aufsetzt, muss wissen, welche Spalten in welchem Typ und Wertebereich erwartet werden, welcher Schwellenwert gilt und welche Modelldatei die richtige ist. Normalerweise steht das verstreut in Notebooks und wird beim Nachbau falsch rekonstruiert.
- Lösung: eine JSON-Datei, die all das enthält, generiert aus den echten Trainingsdaten, nicht aus Annahmen. 30 Pflichtspalten mit Typ, Herkunft und Wertebereich.
- **Stärkster Einzelpunkt, SHA-256:** Beim Laden wird die Prüfsumme jeder Modelldatei neu berechnet und gegen den Eintrag verglichen. Passt sie nicht, bricht die Analyse ab. Damit ist ausgeschlossen, dass die Metadaten ein Modell beschreiben, das inzwischen ein anderes ist.

BEGRIFFE

- **SHA-256:** Kryptografische Hashfunktion. Erzeugt aus beliebigem Inhalt einen Fingerabdruck fester Länge. Schon eine minimale Änderung am Inhalt ändert den Hash vollständig.
- **Schema:** Die formale Beschreibung, welche Spalten mit welchen Typen erwartet werden.

Die Streamlit-Anwendung

Vier Seiten, die jeweils eine konkrete Nutzerfrage beantworten, lauffähig allein aus eingetragenen Artefakten.

SAGEN

- Die vier Seiten kurz benennen, jeweils mit der Frage, die sie beantwortet. Nicht alle Details vorlesen.
- Wichtigster technischer Punkt: Die App braucht keine Notebook-Ausführung. Alle Artefakte, also Modell, Contract, Kennzahlen und Kartendaten, liegen im Repository. Ein Prüfer kann klonen und starten.

JETZT ZEIGEN

App → *Risk Predictor*. In dieser Reihenfolge:

- Abschnitt „**Try an example**“, ein Szenario anklicken. Das füllt alle Felder.
- Kurz durch „**Pick a location**“ (Kartenklick) und „**Accident characteristics**“ scrollen, nicht erklären.
- „**Predict KSI risk**“ drücken, Wahrscheinlichkeit und Schwellenwert zeigen.
- Optional: Seite *Why This Prediction*, Balkendiagramm der Merkmalswichtigkeiten.

Rückfalloption: Startet die App nicht, bleibt diese Folie stehen und ich rede einfach weiter. 60 Sekunden.

BEGRIFFE

- **Streamlit**: Python-Framework, das aus einem Skript eine Web-App macht. Bei jeder Interaktion läuft das Skript komplett neu, Caching verhindert die Wiederholung teurer Berechnungen.
- **Artefakt**: Eine gespeicherte Datei als Ergebnis eines Analyseschritts, hier Modelle, Kennzahlen-CSVs und die Contract-JSON.

Die Risikokarte und die Glättung

Statt absoluter Anteile zeigt die Karte relatives Risiko mit Bayes'scher Glättung, weil sonst 97,5 Prozent der Fläche einfarbig wären.

SAGEN

- Problem zürst, es ist anschaulich: KSI macht bundesweit 18,91 Prozent aus. Färbt man eine Zelle erst rot, wenn die Mehrheit der Unfälle KSI ist, bräuchte sie das 2,64-Fache des Durchschnitts. Das schaffen 123 von 4.857 Zellen. Die Karte wäre praktisch einfarbig.
- Lösung: Nicht „ist die Mehrheit schwer?“, sondern „ist diese Zelle schlechter als der Durchschnitt, und um wie viel?“.
- Zweites Problem, das Glättung nötig macht: Eine Zelle mit drei Unfällen, davon zwei KSI, hätte eine Rate von 67 Prozent, also das 3,5-Fache des Durchschnitts. Das ist reines Rauschen bei drei Beobachtungen.
- **Shrinkage**: Man tut so, als hätte man zusätzlich k Pseudo-Unfälle beobachtet, die exakt dem Bundesdurchschnitt entsprechen. Bei vielen echten Beobachtungen fallen sie kaum ins Gewicht, bei wenigen ziehen sie die Schätzung stark zum Durchschnitt. Im Kern eine Bayes'sche Schätzung mit dem Bundesdurchschnitt als Prior.
- **Warum k gleich 20**, empirisch bestimmt, nicht geraten: Bei k gleich 10 rutschen noch 6-Unfall-Zellen ins höchste Band, bei k gleich 50 bleiben nur 52 Zellen übrig und die Karte wird flach. Bei 20 sind alle fünf Bänder sinnvoll besetzt.
- Schöner UX-Punkt: Zellen mit wenig Evidenz werden blasser gezeichnet. Der Nutzer sieht nicht nur den Schätzwert, sondern auch, wie sicher er ist.

JETZT ZEIGEN

App → *Overview* → Abschnitt „**Where accidents are disproportionately severe**“. Ein oberes Risikoband aus- und wieder einschalten, damit man sieht, wie stark es ausdünnert. Auf eine blasse Zelle deuten und die Konfidenz-Codierung erklären. 45 Sekunden.

WENN GEFRAGT

- **Ist das nicht Manipulation der Daten?** Nein, eine bewusste dokumentierte Verzerrung zugunsten der Robustheit. Ohne Glättung wären die auffälligsten Zellen systematisch die mit den wenigsten Beobachtungen, weil kleine Stichproben die extremsten Raten produzieren. Bei Karten seltener Ereignisse ist das in der Epidemiologie Standard.

Engineering und Qualitätssicherung

Ein Fehler, den die Standard-Tests nicht sehen konnten, führte zu einem zusätzlichen Browser-Test als Pflicht-Gate.

SAGEN, DIE GESCHICHTE KURZ ERZÄHLEN, SIE BLEIBT HÄNGEN

- Die Kartenbibliothek verändert die Objekte, die man ihr übergibt, während sie rendert. Speichert man diese Objekte zwischen, um Zeit zu sparen, referenziert ein späterer Aufruf eine JavaScript-Variable, die es nicht mehr gibt. Die Karte bleibt weiß.
- **Der tückische Teil:** Streamlits eigenes Test-Framework führt keinen Browser aus. Es hat null Fehler gemeldet, während die Karte im Browser kaputt war. Der Test war grün, das Produkt war defekt.
- Konsequenz: ein Headless-Browser-Test, der eine echte Browser-Instanz startet und auf JavaScript-Fehler prüft. Plus ein Test, der die Invariante absichert, dass diese Objekte nie zwischengespeichert werden.
- Restliche Qualitätssicherung kurz: über 440 Tests, Linting, Pre-Commit, CI bei jedem Push, Notebooks im Audit-Modus.

► „Ein grüner Test ist nur so viel wert wie das, was er tatsächlich ausführt.“

BEGRIFFE

- **Headless Browser:** Ein echter Browser ohne sichtbare Oberfläche, für automatisierte Tests.
- **CI:** Continuous Integration. Automatische Ausführung von Tests und Prüfungen bei jeder Änderung im Repository.
- **Linting:** Statische Codeprüfung auf Stil- und Fehlerpotenzial. **Pre-Commit-Hook:** Prüfung, die vor jedem Commit automatisch läuft.

Fazit

Das Modell funktioniert, aber der eigentliche Beitrag liegt in der methodischen Disziplin an drei Stellen, an denen sie etwas gekostet hat.

SAGEN

- Ergebnis nennen: 0,604 und 0,515, beide Gates erfüllt.
- Dann die drei Punkte, jeweils mit der Betonung, dass sie etwas gekostet haben:
 - **Der Negativbefund wurde nicht versteckt.** Es wäre einfacher gewesen, die Drei-Klassen-Ergebnisse wegzulassen und nur das binäre Modell zu zeigen.
 - **Das Reframing war vorab definiert.** Das hat Arbeit gemacht in Phase Q, als noch niemand wusste, dass man es brauchen würde.
 - **Die Test-Trennung wurde eingehalten, obwohl sie wehtat.** Die Entscheidungsmatrix bevorzugt XGBoost. Es wäre attraktiver gewesen, das bessere Modell zu präsentieren.
- Ausblick kurz, vier Stichpunkte, nicht ausführen.

► „Was die Grenze setzt, sind die Daten, nicht das Modell. Kein Algorithmus kann Information erzeugen, die nicht in den Daten steckt.“

Quellen

SAGEN

- Nicht vorlesen. Ein Satz genügt: Datensätze oben, Methodenquellen unten, alle im APA-7-Stil.

WENN NACH FACHLITERATUR ZUR UNFALLFORSCHUNG GEFRAGT WIRD

► „Ich zitiere hier bewusst nur Quellen, die ich vollständig belegen kann, also die Datensätze und die Methodenpapiere zu den eingesetzten Verfahren. Für den Vergleich mit publizierten Ergebnissen aus der Unfallforschung gilt ohnehin eine Einschränkung, die im Repository dokumentiert ist: Solche Studien arbeiten meist mit Personen- und Fahrzeugmerkmalen, die dieser Datensatz nicht hat, oder mit einem anderen Zielformat. Ein direkter Zahlenvergleich wäre deshalb irreführend.“

WARUM DAS EINE STARKE ANTWORT IST

- Sie benennt die Grenze der Vergleichbarkeit selbst, statt sie zu verschweigen.

Vielen Dank

SAGEN

- Kurz halten.
- Auf die drei Artefakte verweisen: Repository, Live-Report, Streamlit-App.
- Fragen einladen.
- Die App im Hintergrund offen lassen, um bei Fragen direkt hineinspringen zu können.

JETZT ZEIGEN

Bei Fragen zur Umsetzung: App → *Why This Prediction* zeigt für die zuletzt berechnete Vorhersage die global wichtigsten Merkmale mit den eigenen Eingabewerten. Gute Antwort auf „Woran sieht man, was das Modell benutzt hat?“.

Die härteste Rückfrage in je einem Satz

- **Warum nicht Accuracy?** 81 Prozent Accuracy bekommt man geschenkt, wenn man immer die häufigste Klasse sagt. Macro-F1 gewichtet jede Klasse gleich.
- **Warum ist das Modell so schwach?** Weil die physikalischen Determinanten fehlen: Aufprallgeschwindigkeit, Insassenalter, Gurtnutzung, Fahrzeugmasse. Die Grenze liegt in den Daten, nicht im Algorithmus.
- **Haben Sie das Ziel geändert, weil es nicht funktioniert hat?** Ja, und das ist dokumentiert. Entscheidend ist: Der Ausweichpfad stand in Phase Q, bevor das erste Modell trainiert wurde, und die ursprüngliche Zielverfehlung wird vollständig berichtet.
- **Warum liefern Sie nicht das bessere Modell aus?** Weil ich dafür den Testsatz ein zweites Mal benutzen müsste. Damit wäre er Teil der Auswahl und keine unabhängige Schätzung mehr. Die Validierung entscheidet, der Test bestätigt nur.
- **Ist Cramér's V 0,13 nicht zu wenig für ein Modell?** Für die Drei-Klassen-Aufgabe ja, das ist der berichtete Negativbefund. Für die binäre KSI-Aufgabe reicht es, weil die positive Klasse dort 19 statt 1 Prozent ausmacht.
- **Kann man damit einzelne Personen bewerten?** Nein, und das war eine vorab festgelegte Ausschlussentscheidung. Der Datensatz enthält keine Personendaten, und die Ergebnisse informieren Infrastrukturentscheidungen.
- **Sind die Merkmalswichtigkeiten Ursachen?** Nein, Assoziationen. Dieser Hinweis steht auch in der App.
- **Warum kein neuronales Netz?** Interpretierbarkeit war eine harte Vorgabe. Ein Verkehrsplaner muss nachvollziehen können, warum ein Ort als Risiko markiert wurde.